

Содержание

1	Введение	1
2	Модели	2
2.1	Свойства и действия агентов	2
2.2	Системы наград и остановки эпизода	3
3	Система обучения	5
3.1	DQN-алгоритм	5
3.2	Уровень исследования	6
4	Глава 1. Одно-агентная задача	7
4.1	Сценарий	7
4.2	Архитектура сети и параметры	7
4.3	Результаты	7
5	Глава 2. Мультиагентная централизованная задача	9
5.1	Архитектура сети	9
5.2	Результаты	9

1 Введение

Обучение с подкреплением (RL) — это универсальный подход для решения различных задачи с оптимальной стратегией. Благодаря стабильной среде и системе явных вознаграждений для агента-исполнителя, этот подход способен обучить агента максимизировать сбор вознаграждений, совершая наиболее полезные действия с точки зрения окружения.

Практический пример применения обучения с подкреплением – задача принятия решений совместно с прогнозированием временных рядов, широко встречаемая в настоящее время в различных отраслях. Такие финансовые задачи имеют четкую систему вознаграждений, легко интерпретируемая как людьми, так и для обучающих алгоритмов, что делает их привлекательными для решения RL-подходами [2, 3].

Однако в реальных задачах временных рядов основная сложность проявляется в ”шоках явлениях непредсказуемого изменения во временном ряду, которые в основном вызваны значимыми мировыми событиями с большим макроэкономическим влиянием или наоборот - чистым совпадением нескольких событий с меньшим влиянием [1]. В результате даже малейшее непредвиденное изменение в динамике временных рядов или статических (не зависящих от действий агентов) аспектах RL-среды, может привести к ошибочным предсказаниям моделями.

Эти события можно предотвратить, внося аналогичные синтетические изменения в сценарии обучения, однако это усложняет процесс обучения RL и требует более дорогой архитектуры.

Подходы глубокого обучения с подкреплением (далее, DRL) могли бы иметь еще большее преимущество в решении экономических проблем с многочисленными состояниями, вбирая в себя не полную информацию об обучении, а лишь наиболее значимые для наград паттерны окружения. Однако DRL-модели также трудно защитить от переобучения и, следовательно, они не устойчивы к потрясениям в рамках обучения стандартным окружениям. Решением может стать дополнительное обучение агента в новых условиях внешней среды «на ходу», с ”теплым”стартом по параметрам модели, предварительно обученной на условиях исходной среды Этот метод потенциально может быть быстрее, чем полное переобучение начиная со случайных параметров и дешевле, чем обучение прогнозированию дополнительных возможных «шоков».

В этой статье мы рассматриваем набор подходов DRL, основанных на методе обучения Deep-Q Network, с возможностью дополнительного обучения, позволяющее реагировать на возникшие ”шоки”в среде путем проведения «горячего» переобучения. Также мы рассмотрим интерактивную задачу о целенаправленном движении объектов. с набором ограничений, аналогичных средам на базе Atari. Представленные в работе сценарии «шоков» среды затронут важнейшие части карты окружения, а также оставят доступные пути успешно решения задачи.

2 Модели

Рассмотрим базовую задачу организации синхронного движения самолетов по наземному пространству аэропорта от ворот до выходов - до условной взлётно посадочной полосы [4]. Проезжая часть представлена в виде матрицы с четырьмя воротами (на левом краю матрицы) и двумя выходами (на правом краю матрицы).

Всем самолетам-агентам разрешено движение только через указанную общую проезжую часть, отмеченную зелеными ячейками на сетке и соответствующим положительным значением в матрице ($=1$) (см. рис 1). Если полет наступит на запрещенную клетку - фиолетовую ячейку карты с нулевым значением в матрице - он получит штраф ϕ . Любые пересечения между траекториями полетов, например, положение любых двух самолетов в одной и той же ячейке или на пересечении унитарных движений на карте запрещены и наказываются штрафом β . Количество выходов намеренно выбрано меньшим, чем количество ворот, чтобы обеспечить тесное взаимодействие между агентами.




Рис. 1: (слева) Карта проезжей части аэропорта: зеленые ячейки ($=1$) — разрешенные ячейки, темные клетки ($=0$) запрещены к перемещению, желтая клетка — пункт назначения на рейсе ($=10$); (справа) положение рейса на карте в иде матрицы: желтая ячейка ($=1$) обозначает позицию самолета ($=1$), а темная ячейка ($=-1$) описывает текущее направление движения

2.1 Свойства и действия агентов

Каждый рейс или Агент имеет позицию на карте в виде ячейки сетки, в которой он находится в дискретный момент t .

$$\mathbf{s}_t = \{s_t^i\}_{i=1}^N \quad (2.1)$$

Мы считаем, что максимальное число агентов N равно ограничено количеством ворот. Чтобы обеспечить более свободное перемещение по карте, агенту было добавлено новое свойство - базовое направление i -го полета.

$$\mathbf{v}_t = \{v_t^i\}_{i=1}^N, v \in (\{-1, 0, 1\} \times \{-1, 0, 1\}) \setminus (0, 0) \quad (2.2)$$

Это необходимо для применения направленных движений по карте, делённых на три группы:

- Движения без изменения направления: шаг вперед в текущем направлении полета и остановка, фиксирующая положение самолёта на один временной шаг

$$\begin{cases} s_{t+1}^i = s_t^i + v_t^i * f \\ f = 1 \text{ if step = 'forward', else } 0 \\ v_{t+1}^i = v_t^i \end{cases} \quad (2.3)$$

- Небольшие повороты: движения с поворотом базового направления на 45 градусов и шагом вперед в измененном направлении

$$\begin{cases} v_{t+1}^i = rotate(v_t^i, \pm 45^\circ) \\ s_{t+1}^i = s_t^i + v_{t+1}^i \end{cases} \quad (2.4)$$

- Крутые повороты: движения в текущем направлении, но с последующим изменением конечного направления на 90 градусов.

$$\begin{cases} s_{t+1}^i = s_t^i + v_t^i \\ v_{t+1}^i = rotate(v_t^i, \pm 90^\circ) \end{cases} \quad (2.5)$$

Итоговый набор движений, возможный для совершения самолетом в одном направлении представлен на графике ???. Так, будучи в точке $s_0 = (0,0)$ в направлении $v = (1,0)$, самолёт может продвинуться вперёд, до точки $(1,0)$ или, совершив небольшой поворот на 45 градусов, сместиться в точку $(1,-1)$ или $(1,1)$ - тогда его направление изменится на 45 градусов по часовой или против часовой стрелки соответственно. Наконец, для совершения более крутого поворота, самолёт-агент может продвинуться в точку $(1,0)$ и сменить направление до $(0, \pm 1)$.

Применяемый комплекс действий подчеркивает инертный характер маневров самолета - требуется несколько шагов и дополнительное пространство для разворота самолета при движении по проезжей части. Например, требуется выполнить два одинаковых резких поворота или четыре небольших поворота, чтобы изменить направление самолета на противоположное. Однако, поскольку в данной работе скорость самолета не учитывается, его остановка происходит всегда мгновенно, но сопровождается штрафом γ .

Чтобы стимулировать скорейшее движение к выходам, в окружение втронен фоновый штраф α , который применяется к полету на каждом шаге.

Последним дополнением к свойствам полета является пункт назначения – ячейка одного из выходов на карте проезжей части - эта точка является главной целью задания в окружении для каждого самолёта.

$$d^i \in \{(9,2), (9,5)\} = D \quad (2.6)$$

Назначаемый для каждого самолёта выход, который, как правило, располагается ближе всего к воротам, из которых появился рейс. За достижение пункта назначения к успешным самолетам применяется положительная награда θ . Если самолет попадает к другому выходу, не запланированному для него, награда также выдаётся, но уменьшенная.

2.2 Системы наград и остановки эпизода

Все вышеописанные ранее правила окружения можно описать в системе уравнений наград:




Рис. 2: Карта всех возможных действий с позиции (0,0) и направления (1,0) (синяя точка) и будущие состояния (оранжевые точки — позиции и стрелки — направления), включая «остановку» на том же месте.

$$r_t^i = -\alpha + \begin{cases} -\gamma, & \text{if } s_{t-1}^i = s_t^i \\ -\beta, & \text{if } \exists \tau_0 : s_t^i + \tau_0 u_t^i = s_t^j + \tau_0 u_t^j \\ & i \neq j, \tau_0 \in (0,1] \\ -\phi, & \text{if } s_t^i \text{ is not a permitted cell} \\ \theta, & \text{if } s_t^i = d^i \\ \theta_r, & \text{if } s_t^i \in D \setminus d^i \end{cases}$$

$$\alpha, \beta, \phi, \theta, \theta_r, \gamma > 0, \theta > \theta_r, \gamma > \alpha \quad (2.7)$$

Если самолет получает одну из условных наград (любую кроме базовой награды $-\alpha$ и штрафа за остановку $-\gamma$), самолет становится неактивным, а его последующие награды аннулируются до конца эпизода. Однако агенты могут покинуть карту окружения только через выходы справа, поэтому после его выхода из строя, даже в неактивном режиме он все равно останется препятствием для других активных агентов (ячейка, где остановился вышедший из строя самолет, становится неразрешенной). Эпизод заканчивается после того, как все рейсы станут неактивными. Продолжительность эпизода ограничена 12 шагами, поэтому, если какой-либо из самолётов остался активным до ”дедлайна эпизод обрывается.

3 Система обучения

Фреймворк обучения рассматривается практически такой же, как был в работе [?]. Мы рассматриваем фреймворк с алгоритмом обучения Deep-Q Network и ϵ -жадной политикой.

3.1 DQN-алгоритм

Алгоритм Deep-Q Network - это стандартный безмодельный алгоритм обучения агента в виде нейронной сети на принятии решения в среде.

Каждое взаимодействие между агентом или несколькими агентами с окружением хранится в виде элемента Марковской цепи решений (MDP), состоящего из:

- Некоторого состояния окружения s_0
- Набора действий каждого агента при этом состоянии (одно на каждого агента)
- Награда за совершение этих действий
- Нового состояния-результата s_1

Элементы (или переходы Марковской цепи) хранятся в **воспроизводящей памяти** RM ограниченного объёма N - она применяется в обучении нейронной сети агента.

В алгоритме используется обучение двух нейронных сетей:

- Тренировочная сеть Q_{policy} - обучается явным образом на каждом шаге эпизода
- Целевая сеть Q_{target} - обучается неявно путём линейного смещения параметров в сторону параметров тренировочной сети с небольшим коэффициентом, тем самым ограничивая её от переобучения:

$$Q'_{target} = (1 - \tau)Q_{target} + \tau Q_{policy} \quad (3.1)$$

Именно целевая нейронная сеть является результирующей политикой агента после обучения. Тренировочная сеть используется для основной коммуникации с окружением и генерации MDP-элементов, заносимых в воспроизводящую память для обучения.

Для выбора действия, нейронная сеть агента предсказывает награду, которую он получит за совершение j -го действия. В итоге окружением совершается действие, имеющее максимальную предсказанную награду.

$$\begin{aligned} \hat{r}_t &= Q(s_t) \\ r_t(a^j) &= \hat{r}_t^j a_t^* = \operatorname{argmax}_a(r_t(a)) \end{aligned}$$

Обучение тренировочной сети проходит после каждого ввода нового MDP-элемента со следующим алгоритмом:

1. Берётся сет из N_B случайно взятых переходов из воспроизводящей памяти

2. Рассчитывается целевая награда сета - сумма награды после изначального состояния и награды за действия выбранные целевой политикой на новом состоянии s_{t+1} :

$$r_{target} = r_t + \gamma \tau Q_{target}(s_{t+1}) \quad (3.2)$$

, где γ - это коэффициент дисконтирования награды, снижающий значимость награды, полученную на более поздних ходах

3. Предсказанная награда сета - это награда за действия выбранные тренировочной сетью на изначальном состоянии:

$$r_{policy} = Q_{policy}(s_{t+1}) \quad (3.3)$$

4. Обучение тренировочной сети происходит путём оптимизации функции потерь Хубера между целевой (3.2) и предсказанной (3.3) наградами.

$$Q'_{policy} = Q_{policy} + \beta \nabla_Q L_\delta(r_{target}, r_{policy}) \quad (3.4)$$

Тем самым, тренировочная модель "мотивирована" искать шаги, позволяющие за один ход получить награду, ранее достигаемую за два хода целевого агента, и следовательно - достигать цели наиболее быстрыми методами.

5. Наконец, производится обновление параметров целевой политики по уравнению (3.1).

3.2 Уровень исследования

Уровень исследования - это вероятность, с которой на каждом шаге генерации MDP-перехода обучающийся агент выберет случайное действие, вместо результата собственной обработки состояния окружения. Она является функцией от номера эпизода и рассчитывается как:

$$\epsilon(n) = 0.05 + 0.9 \max(1 - \frac{n + n_r}{N_{total}}, 0), n \leq N_{total}$$

где N_{total} — общее количество обучающих эпизодов, а n_r — количество последних эпизодов, в которых скорость исследования минимальна.

В случае нашей основной задачи окружения, в виду существования обширной запрещенной зоны, случайный выбор действия часто приводит к большому числу провальных попыток во время обучения.

Однако данная функция всё же сохраняет особую важность в глубоком обучении с подкреплением, так как придаёт памяти разнообразие состояний окружений и действий агента в обучающем "датасете".

В работе n_r фиксируется как в процессе обучения, так и в процессе послешокового переобучения и составляет 500 эпизодов.

4 Глава 1. Одно-агентная задача

В рамках первого эксперимента рассмотрим сценарий задачи с одним агентом - такой формат обучения будет освобожден от ограничений взаимодействия с другими агентами в виду их отсутствия, и позволит максимально пристально оценить влияние шока и эффективность послешокового обучения.

4.1 Сценарий

Эксперименты проводятся для одного самолета, движущегося из каждого входа слева со следующим сценарием.

1. Сначала базовый агент обучается движению от ворот до ближайшего к воротам выхода - по одному отдельному агенту на ворота
2. После обучения, проводится эксперимент окружения на целевой сети с введением шока: на пути к предобученному пункту назначения, назначенный выход закрывается и проводится попытка продолжить выполнение эпизода - новым пунктом назначения выбирается последний оставшийся выход. Шаг введение шока в окружение можно варьировать, но для экспериментов выбираются такие моменты, чтобы после введения шока у агента оставалось пространство для маневрирования.
3. Инициализируется процесс дообучения модели с тёплым стартом (с параметрами базовой модели в качестве начальных) с задачей перемещения самолёта от точки, в которой произошёл шок, до нового пункта назначения.

4.2 Архитектура сети и параметры

Состояние окружающей среды декодируется как изображение с двумя слоями – картой и положением плоскости (см. рисунок 1), итоговая форма изображения - $2 \times 9 \times 10$.

Нейронная сеть состоит из следующих слоев:

- Сверточный слой с фильтром размера $2 \times 3 \times 3$, одним входным и 8 выходными слоями
- Сверточный слой с фильтром размера 3×3 , 8 входными и 16 выходными слоями
- Сверточный слой с фильтром размера 3×3 , 16 входными и 32 выходными слоями
- Сверточный слой с фильтром размера 3×3 , 32 входными и 64 выходными слоями
- Полносвязный слой с 128 входами and 6 выходами (равно количеству доступных действий)

4.3 Результаты

Результаты эксперимента продемонстрированы на рисунке 5 в приложении. В каждой строке показаны результаты обучения и переобучения одного агента из разных ворот.

Траектории базовых обученных агентов изображены в левом столбце. Каждый агент выполнил свои задачи и сумел добраться до места назначения (самолёты из двух верхних ворот добрались до верхнего выхода, а из двух нижних ворот - к нижнему выходу).

Объём обучающего сета N_B	500
дисконт. коэф-ент γ	0.99
функция потерь L_Q	Huber loss
алгоритм оптимизации	Adam
коэф-ент оптимизации β	10^{-4}
n_r	500

Таблица 1: Параметры обучения моделей

В средней колонке траектория выполнялась по нетронутой карте окружения до красного креста, где находился самолет, когда произошел шок и закрылись ворота, запланированные как пункт назначения. Последний доступный выход становится новым пунктом назначения, и эксперимент продолжается. Следующие шаги агента приводили к сбою (первый и третий самолеты наступили на неразрешенную ячейку) или к завершению эпизода по истечению времени (второй самолет остановился, а четвертый самолет шел по карте, пока не достиг предела шага).

Траектории переобученных моделей показаны в правых столбцах. Задача переобученного агента заключалась в том, чтобы проследовать к последнему доступному выходу, начиная из точки, где произошел шок (красный крест), а не со стартовых ворот. Каждому агенту удалось добраться до другого выхода и выполнить задачу после того, как произошел шок окружения.

Из таблицы 2 хорошо видно, что процесс послешокового дообучения занял значительно меньше эпизодов и воспроизводящей памяти, чем первоначальное обучение, что видно из рисунков 3 и 4.

Это можно объяснить отсутствием принципиальных различий (как например в системе наград или пространстве действий агента) между базовой и измененной окружающей средой и сохранением фундаментальных «знаний» о правилах окружающей среды в процессе дообучения.

этап обучения	базовый	послешоковый
число эпизодов	5000	1500
объём ВП	10000	1000
ур. обучения целовой сети τ	0.1	0.2

Таблица 2: Гиперпараметры обучения и базовой и послешоковой модели

Результаты эксперимента показывают временную (при значительно меньшем количестве эпизодов) и ресурсную эффективность (за счет меньшего объема памяти повторов) метода постшокового дообучения даже при минимальной настройке гиперпараметров обучения агентов в случае экологических синтетических шоков.

5 Глава 2. Мультиагентная централизованная задача

Следующий этап работы - решение задачи передвижения нескольких самолётов по проезжей части аэропорта, от ворот до ближайших выходов. В первую очередь будет опробован централизованный подход, где агентом выступает ”диспетчер организующий движение каждого самолёта на карте одновременно. На вход агент также получает одновременно одно состояние, описывающие положения, направления и карты проезжей части с отмеченными пунктами назначения каждого самолёта, и на основе всей информации от каждого самолёта принимается решение об их перемещениях. По сравнению с обучающим процессом из предыдущей главы, задача усложняется большим количеством принимаемых решений и менее явным возвращаемым значением награды - в случае централизованного подхода, награда равна сумме наград каждого подагента (5.1), то есть оценивается влияние диспетчера на всю систему в целом. Вследствие этого агенту сложнее определить, какие действия на каком самолёте оказались более успешными.

$$R_t = \sum_i r_t^i \quad (5.1)$$

Сценарий эксперимента с применением шока остаётся неизменным по сравнению с одно-агентной задачей.

5.1 Архитектура сети

5.2 Результаты

Список литературы

- [1] Nathan S Balke and Thomas B Fomby. Large shocks, small shocks, and economic fluctuations: Outliers in macroeconomic time series. *Journal of Applied Econometrics*, 9(2):181–200, 1994.
- [2] James J Choi, David Laibson, Brigitte C Madrian, and Andrew Metrick. Reinforcement learning and savings behavior. *The Journal of finance*, 64(6):2515–2534, 2009.
- [3] Zara Andreia Albino Madureira. *Ensemble reinforcement learning to forecast time series data: a performance analysis*. PhD thesis, 2023.
- [4] Shin-Lai Tien, Huang Tang, Daniel Kirk, Erik Vargo, and Sheng Liu. Deep reinforcement learning applied to airport surface movement planning. In *2019 IEEE/AIAA 38th Digital Avionics Systems Conference (DASC)*, pages 1–8. IEEE, 2019.




Рис. 3: History of the training episode rewards of the model of the single flight (planes from the first and the second gates) during base training (on the left from the vertical line) and during the after-shock retraining (on the right after the vertical line). The dots are the values of the each episode reward: red dots are failed episodes, black dot are truncated episode with no certain result, green dots are successful episodes. Blue line is the moving average through 100 episodes.




Рис. 4: History of the training episode rewards of the model of the single flight (planes from the third and the fourth gates) during base training (on the left from the vertical line) and during the after-shock retraining (on the right after the vertical line). The dots are the values of the each episode reward: red dots are failed episodes, black dot are truncated episode with no certain result, green dots are successful episodes. Blue line is the moving average through 100 episodes.




Рис. 5: Results of the retraining experiments: (left) trajectory of the trained base agent in non-shocked scenario; (center) trajectory of the trained base agent with planned shock (the shock occurred while the flight was on the crossed cell); (right) trajectory of the retrained agent after the shock ;